

22.05.24

[1-3] Dane są obserwacje x_1, \dots, x_n , pochodzące z wymienionych rozkładów. Znaleźć estymator dla parametrów (metoda MLE)

1) F-ja wiarygodności $L(p) = \prod_{i=1}^n f(x_i | p)$

2) $l(p) = \log(L(p))$

3) $\frac{\partial L(p)}{\partial p} = 0 \rightarrow$ szukamy p

4) $\frac{\partial^2 L(p)}{\partial p^2} \leq 0 \rightarrow p\text{-maximum}$

zad 1Geom(p), parametr p

1) $f(x_i | p) = (1-p)^{x_i} \cdot p$ gdzie $x_i \in \{1, 2, \dots\}$

$$L(p) = \prod_{i=1}^n f(x_i | p) = \prod_{i=1}^n (1-p)^{x_i} \cdot p =$$

$$= \prod_{i=1}^n (1-p)^{x_i} \cdot \prod_{i=1}^n p =$$

$$= (1-p)^{\sum_{i=1}^n x_i} \cdot p^n$$

Zauważmy, że

$$\prod_{i=1}^n x_i^m = x^{\sum_{i=1}^n m}$$

2) $l(p) = \log L(p) = \log [(1-p)^{\sum_{i=1}^n x_i} \cdot p^n] =$

$$= \sum_{i=1}^n x_i \cdot \log(1-p) + n \cdot \log p$$

3) $\frac{\partial L(p)}{\partial p} = \frac{1}{1-p} \cdot (-1) \cdot \sum_{i=1}^n x_i + \frac{1}{p} \cdot n$

$$\left. \frac{\partial L(p)}{\partial p} \right|_{p=\hat{p}} = 0 \Leftrightarrow -\frac{1}{1-\hat{p}} \cdot \sum_{i=1}^n x_i + \frac{n}{\hat{p}} = 0$$

4) $\frac{\partial^2 L(p)}{\partial p^2} = -\frac{1}{(1-p)^2} \sum_{i=1}^n x_i - \frac{n}{p^2}$

$$- \left[\underbrace{\frac{1}{(1-p)^2}}_{>0} \underbrace{\sum_{i=1}^n x_i}_{>0} + \underbrace{\frac{n}{p^2}}_{>0} \right] < 0$$

bo $(1-p)^2 > 0$ cyli > 0

$$\frac{n}{\hat{p}} = \frac{\sum_{i=1}^n x_i}{1-\hat{p}}$$

$$\frac{1-\hat{p}}{\hat{p}} = \frac{\sum_{i=1}^n x_i}{n}$$

$$\frac{1}{\hat{p}} = \frac{\sum_{i=1}^n x_i}{n} + 1 \Leftrightarrow \frac{\sum_{i=1}^n x_i + n}{n} = \frac{1}{\hat{p}}$$

Wiemy że to jest średnia cyli \bar{x}

$$\bar{x} = \frac{1}{\hat{p}}$$

$$\hat{p} = \frac{1}{\bar{x}}$$

zad 2

Rozkład Pareto, $f(x, a, k) = \frac{k a^k}{x^{k+1}}$, $x \in [a, \infty)$, k - znane,
parametr a

$$1) L(x; a, k) = \prod_{i=1}^n \frac{k \cdot a^k}{x_i^{k+1}} = k^n \cdot a^{kn} \cdot \prod_{i=1}^n \frac{1}{x_i^{k+1}}$$

$$2) l(x; a, k) = n \cdot \log(k) + nk \cdot \log(a) - (k+1) \sum_{i=1}^n \log x_i$$

$$3) \frac{\partial l(x; a, k)}{\partial(a)} = 0 + \frac{nk}{a} - 0 = 0$$

Ale tutaj dochodzimy do sprzeczności ⚡
bo $n > 0, k > 0$

To znaczy, że f -ja nie ma maximum
↓

Ale z zał. $x \in [a, \infty)$, czyli $x \geq a$,

więc $a = \min \{x_i\}$.

zad 8 Prosta regresji dla danych:

x_k	1	3	4	6	8	9	11	14
y_k	1	2	4	4	5	7	8	9

$$\hat{y}_i = a + b \cdot x_i$$

$$a = \bar{y} - b \cdot \bar{x}$$

$$b = n \cdot \frac{\sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \cdot \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} \quad n=8$$

Wtedy: $\sum x_i y_i = 364$
 $\sum x_i^2 = 524$
 $\sum x_i = 56$ $\sum y_i = 40$
 $(\sum x_i)^2 = 3136$

$$b = \frac{8 \cdot 364 - 56 \cdot 40}{8 \cdot 524 - 3136} = \frac{672}{1056} = \frac{7}{11}$$

$$\bar{y} = \frac{\sum y_i}{n} = \frac{40}{8} = 5$$

$$\bar{x} = \frac{\sum x_i}{n} = \frac{56}{8} = 7$$

$$a = 5 - \frac{7}{11} \cdot 7 = 5 - \frac{49}{11} = \frac{6}{11}$$

Prosta regresji: $\hat{y}_i = \frac{6}{11} + \frac{7}{11} \cdot x_i$

[zad 4]

Dane punkty $(x_1, y_1), \dots, (x_n, y_n)$.

Stukamy krzywej regresji $y = a + bx + cx^2$

Uzasadnić, że a, b, c są rozwiązaniem układu:

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \cdot \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \\ \sum x_i^2 y_i \end{bmatrix}$$

Regresja kwadratowa (metoda najmniejszych kwadratów)

Cel: znaleźć takie a, b, c , które minimalizują sumę kwadratów błędów:

$$S(a, b, c) = \sum_{i=1}^n (y_i - (a + bx_i + cx_i^2))^2 \quad \text{funkcja kosztu}$$

Aby znaleźć a, b, c ; obliczymy pochodne cząstkowe i przyrównujemy do 0:

$$\frac{\partial S}{\partial a} = -2 \sum_{i=1}^n (y_i - a - bx_i - cx_i^2) = 0$$

$$\frac{\partial S}{\partial b} = -2 \sum_{i=1}^n x_i (y_i - a - bx_i - cx_i^2) = 0$$

$$\frac{\partial S}{\partial c} = -2 \sum_{i=1}^n x_i^2 (y_i - a - bx_i - cx_i^2) = 0$$

$$\begin{cases} na + \sum x_i b + \sum x_i^2 c = \sum y_i \\ \sum x_i a + \sum x_i^2 b + \sum x_i^3 c = \sum x_i y_i \\ \sum x_i^2 a + \sum x_i^3 b + \sum x_i^4 c = \sum x_i^2 y_i \end{cases}$$

a to jest dokładnie to samo, co wyżej

[zad 5]

Punkty $(x_1, y_1, z_1), \dots, (x_n, y_n, z_n)$

Równanie regresji $z = a + bx + cy$. Uzasadnić, że a, b, c są rozwiązaniem

$$\begin{bmatrix} n & \sum x_i & \sum y_i \\ \sum x_i & \sum x_i^2 & \sum x_i y_i \\ \sum y_i & \sum x_i y_i & \sum y_i^2 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} \sum z_i \\ \sum x_i z_i \\ \sum y_i z_i \end{bmatrix}$$

$$S(a, b, c) = \sum (z_i - \hat{z}_i)^2 = \sum (z_i - (a + bx_i + cy_i))^2$$

$$\frac{\partial S}{\partial a} = -2 \sum (z_i - (a + bx_i + cy_i)) = 0$$

$$\frac{\partial S}{\partial b} = -2 \sum x_i (z_i - (a + bx_i + cy_i)) = 0$$

$$\frac{\partial S}{\partial c} = -2 \sum y_i (z_i - (a + bx_i + cy_i)) = 0$$

znowy jak w **[zad 4]**

zad 2

Rozkład Pareto, $f(x, a, k) = \frac{k a^k}{x^{k+1}}$, $x \in [a, \infty)$, k - znane,
parametr a

$$1) L(x; a, k) = \prod_{i=1}^n \frac{k \cdot a^k}{x_i^{k+1}} = k^n \cdot a^{kn} \cdot \prod_{i=1}^n \frac{1}{x_i^{k+1}}$$

$$2) L(x; a, k) = n \cdot \log(k) + nk \cdot \log(a) - (k+1) \sum_{i=1}^n \log x_i$$

$$3) \frac{\partial L(x; a, k)}{\partial(a)} = 0 + \frac{nk}{a} - 0 = 0$$

Ale tutaj dochodzimy do sprzeczności ⚡
bo $n > 0, k > 0$

To znaczy, że f -ja nie ma maximum
↓

Ale z zał. $x \in [a, \infty)$, czyli $x \geq a$,

wiec $a = \min \{x_i\}$.

zad 8

Prosta regresji dla danych:

x_k	1	3	4	6	8	9	11	14
y_k	1	2	4	4	5	7	8	9

$$\hat{y}_i = a + b \cdot x_i$$

$$a = \bar{y} - b \cdot \bar{x}$$

$$b = n \cdot \frac{\sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \cdot \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} \quad n = 8$$

Wtedy: $\sum x_i y_i = 364$

$$\sum x_i^2 = 524$$

$$\sum x_i = 56 \quad \sum y_i = 40$$

$$(\sum x_i)^2 = 3136$$

$$b = \frac{8 \cdot 364 - 56 \cdot 40}{8 \cdot 524 - 3136} = \frac{672}{1056} = \frac{7}{11}$$

$$\bar{y} = \frac{\sum y_i}{n} = \frac{40}{8} = 5$$

$$\bar{x} = \frac{\sum x_i}{n} = \frac{56}{8} = 7$$

$$a = 5 - \frac{7}{11} \cdot 7 = 5 - \frac{49}{11} = \frac{6}{11}$$

Prosta regresji: $\hat{y}_i = \frac{6}{11} + \frac{7}{11} \cdot x_i$